My Re-implemnted SAM by reading the paper Segment Anything [ICCV, 2023]

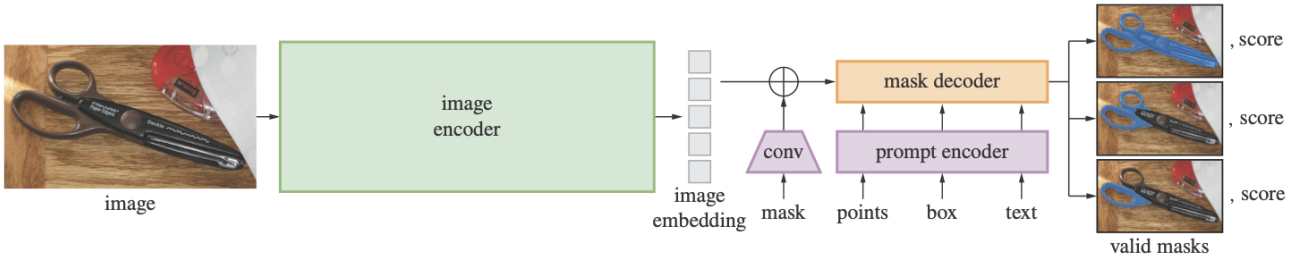

Figure 4: Segment Anything Model (SAM) overview. A heavyweight image encoder outputs an image embedding that can then be efficiently queried by a variety of input prompts to produce object masks at amortized real-time speed. For ambiguous prompts corresponding to more than one object, SAM can output multiple valid masks and associated confidence scores.

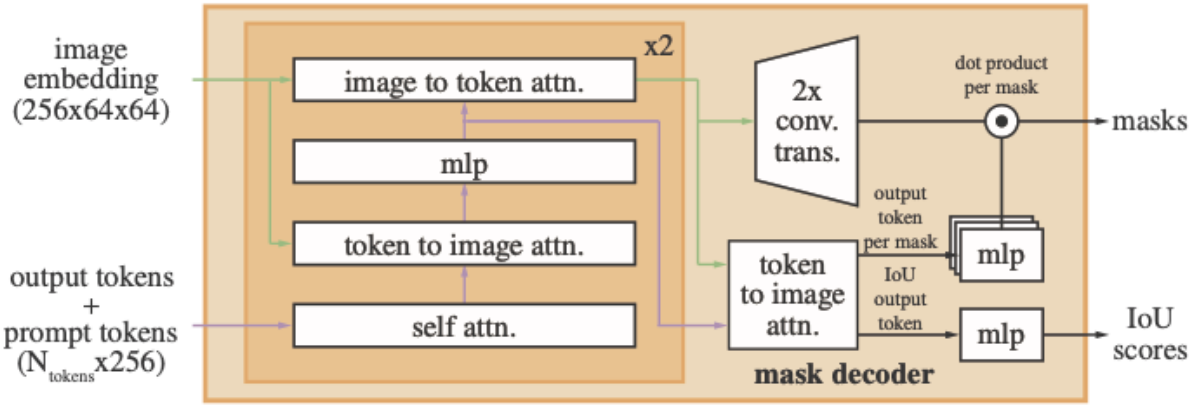

Figure 14: Details of the lightweight mask decoder. A two-layer decoder updates both the image embedding and prompt tokens via cross-attention. Then the image embedding is upscaled, from which the updated output tokens are used to dynamically predict masks. (Not illustrated for figure clarity: At every attention layer, positional encodings are added to the image embedding, and the entire original prompt token (including position encoding) is re-added to the token queries and keys.)

For re-implementation, I reffered not only the content but also appendix. The implementation part was mainly the overall arghitecture shown in figure 4, and the detailed model

This work was done for the assignment below.

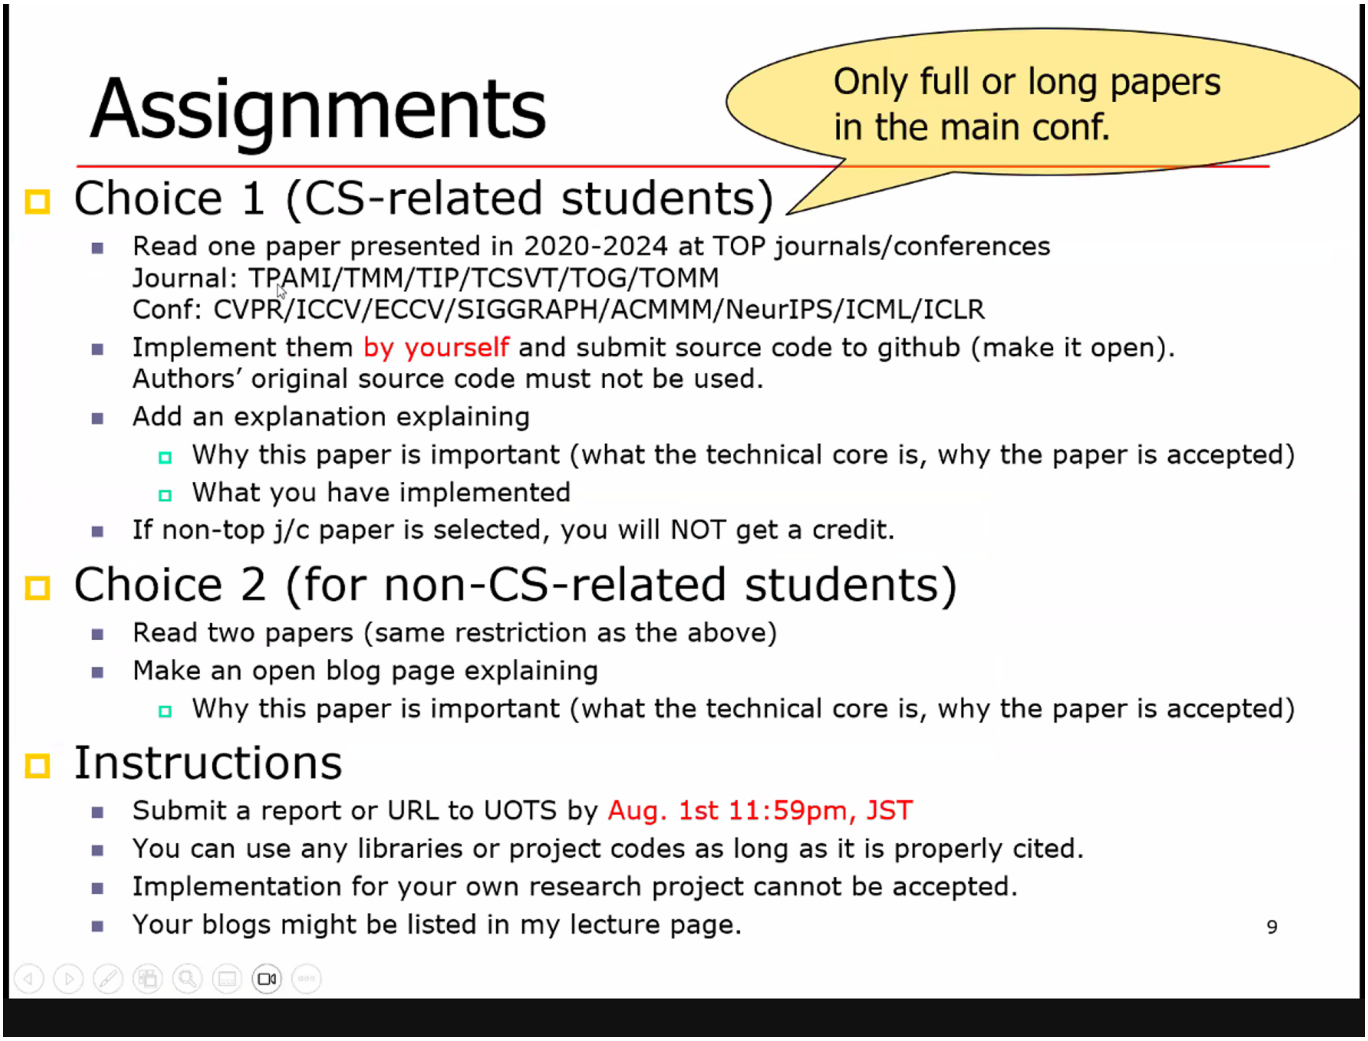

ヒント architecture 初期化 (**init** メソッド):

image_encoder, prompt_encoder, mask_decoder の3つの主要なコンポーネントを初期化します。 入力画像の正規化に使用する平均 (pixel_mean) と標準偏差 (pixel_std) をバッファに登録します。 順伝播 (forward メソッド):

バッチ入力を受け取り、画像を前処理してエンコードします。 エンコードされた画像からポイントやボックス、マスクなどのプロンプトをエンコードします。 マスクデコーダーを使って低解像度マスクとIoU予測を生成します。 マスクを元の画像サイズに後処理し、結果をリストに格納して返します。 マスクの後処理 (postprocess_masks メソッド):

低解像度のマスクを元の画像サイズにリサイズし、パディングを除去します。 前処理 (preprocess メソッド):

画像を正規化し、必要に応じてパディングを追加して正方形の入力に変換します。